






VertexAI

PME vente de service à abonnement

Prédiction : départs de clients, demande, fraude



Pas d'équipe MLOps

Data scientists rares et
chers



Obtention de résultats
rapides




Budget prévisible






Depuis 2023 GenAI :
Gemini, Model garden, Vertex AI
studio, RAG, Agent builder

Data :
BigQuery / GCS



Train :
AutoML / Custom



Évaluer :
Métrique / XAI



Cycle de vie



Servir :
Endpoint / batch




Monitorer :
Drift / skew






Depuis 2023 GenAI :
Gemini, Model garden, Vertex AI
studio, RAG, Agent builder

Data :
BigQuery / GCS



Train :
AutoML / Custom



Cycle de vie


Évaluer :
Métrique / XAI



Servir :
Endpoint / batch




Monitorer :
Drift / skew



réentraînement





01

Briques et intérêt

AutoML (tabular, image, texte)

Modèle sans code



Prediction et endpoints

Servir : online (REST) ou batch



Model Garden + gemini

Catalogue + API GenAI



Custom training

Notre code (TF/PyTorch/sklearn)



Model registry / monitoring

Versionner, détecter la dérive



Pipeline / feature store


MLOps avancés





02

Intégration





03

PoC : prédiction de churn



Hypothèse : Acquérir un nouveau client coûte 5x plus cher que d'en retenir un



Prédire qui risque de partir pour les retenir


Pourquoi AutoML Tabular ?

- CSV de clients
- Pas besoin de coder un modèle
- Livre un modèle + importance des features exploitables



03


PoC : architecture





03

PoC : démonstration





04

Évaluation : bénéfices



Time-to-Model



Zéro infra



Services unifiés



Explicabilité




04


Évaluation : Risques et limites




Vendor Lock-in



Coûts imprévisibles



Boite noire



Complexe à maturité

Solution mouvante



04

Évaluation : Vendor lock-in



AutoML, Feature store,
Pipelines, API Gemini

Abstraction



Endpoints, SDK *aiplatform*,
format datasets

Encapsulation



Custom training, données
GCS/BigQuery, Modèle OSS
du Model Garden

Formats ouverts
(Parquet/SQL)



05

Coûts : Structure et scénario chiffré

Modèle : Paiement à l'usage (compute + stockage) facturé à la seconde.

- Entraînement AutoML Tabular : 21\$/node-heure
- Endpoint online n1-standrad-4 : 0,22\$/h = 160\$/mois en 24/7
- Batch : Seulement le compute
- Gemini : au token

Poste	Endpoint 24/7	Batch mensuel
Entraînement (2 node-h/mois)	42\$	42\$
Serving	160\$	8\$
Stockage + notebook dev	15\$	15\$
Total / mois	217\$ (~195CHF)	65\$ (~60CHF)



05

Coûts : Alternatives et positionnement



SageMaker : Équivalent direct, plus riche mais plus complexe



ML : Équivalent direct, meilleur pour l'intégration Microsoft



databricks

MLflow : Lakehouse multi-cloud, moins «no code»



Open source : (scikit learn, FastAPI, Airflwo), moins cher, contrôle total, mais il faut tout maintenir




API GenAI : (OpenAI, Anthropic, HF), pour la GenAI pure, sans MLOps

CONCLUSION



- Déjà sur GCP / BigQuery
- Peu ou pas d'équipe MLOps
- Time-to-model critique
- Données tabulaires / images standards
- Charge variable



- Besoin simple et stable
- Petit budget + trafic faible
- Exigence de portabilité / souveraineté
- Besoin de contrôle fin sur l'algo
- Multi-cloud imposé

Vertex AI : Raccourci puissant pour faire du ML sans équipe dédiée



Références

- cloud.google.com/vertex-ai
- cloud.google.com/vertex-ai/docs
- cloud.google.com/vertex-ai/pricing
- Tuto AutoML Tabular (docs)
- SDK Python google-cloud-aiplatform

À retenir

- 3 briques utiles : AutoML · Serving · Gemini
- Coût = compute + stockage, à l'usage
- Endpoint always-on = piège n°1
- Données restent exportable
- Vertex AI est pertinent pour une PME qui veut aller vite sans équipe MLOps

